

گزارش جامع مقایسه مدل‌های هوش مصنوعی (منبع باز و اختصاصی) و تحلیل هزینه‌ها

۱. مقدمه

در سال ۲۰۲۶، شکاف عملکردی بین مدل‌های منبع باز (Open Source) و مدل‌های اختصاصی (Closed Source) به حداقل رسیده و مدل‌های منبع باز با هزینه‌ای بسیار کمتر، عملکردی نزدیک به بهترین مدل‌های تجاری ارائه می‌دهند. این گزارش به بررسی جامع مدل‌های موجود، قیمت‌گذاری API، سناریوهای مختلف مصرف کاربران، و تحلیل نقطه سر به سر (Break-Even) بین استفاده از API و میزبانی اختصاصی (Self-Hosted) می‌پردازد.

۲. فهرست جامع مدل‌ها

۱-۲. مدل‌های منبع باز (Open Source)

نام مدل	سازمان	معماری	کل پارامتر	پارامتر فعال	پنجره زمینه	مجوز	چندرسانه‌ای
Llama 4 Maverick	Meta	MoE	۴۰۰ میلیارد	۱۷ میلیارد	۱ میلیون توکن	Llama 4 Comm.	بله
Llama 4 Scout	Meta	MoE	۱۰۹ میلیارد	۱۷ میلیارد	۱۰ میلیون توکن	Llama 4 Comm.	بله
Qwen3.5-Plus	Alibaba	Dense	—	—	۱ میلیون توکن	Open	خیر
Qwen3-Max	Alibaba	MoE	۱~ تریلیون	—	۲۵۲ هزار	Open	خیر
Qwen3-Coder-Next	Alibaba	MoE	۸۰ میلیارد	۳ میلیارد	۲۶۲ هزار	Apache 2.0	خیر

د								
متن/تصویر/صوت/ویدئو	MIT	۱ میلیون	۱۵ میلیارد	۳۱۰ میلیارد	Sparse MoE	شیائومی	MiMo-V2.5	
خیر	Open	۱ میلیون	—	—	—	DeepSeek k	DeepSeek V4 Flash	
خیر	Open	۱ میلیون	—	—	—	DeepSeek k	DeepSeek V4 Pro	
خیر	Open	—	—	—	MoE	Zhipu AI	GLM-5.1	

۲-۲. مدل‌های اختصاصی (Closed Source)

نام مدل	سازمان	پنجره زمینه	چندرسانه‌ای	ویژگی‌ها
GPT-4o	OpenAI	۱ میلیون	بله	استاندارد صنعت، اکوسیستم گسترده
GPT-5.5	OpenAI	۱ میلیون	بله	جدیدترین نسخه، توانایی استدلال پیشرفته
Claude Sonnet 5	Anthropic	—	بله	تعادل عملکرد و هزینه
Claude Opus 4.7	Anthropic	۱ میلیون	بله	بالاترین دقت در کدنویسی و استدلال
Gemini 1.5 Pro	Google	۲ میلیون	بله	توانایی چندرسانه‌ای قوی

۳. مقایسه عملکرد (Open Source در مقابل Closed Source)

جدول زیر شاخص‌های کلیدی عملکرد را نشان می‌دهد:

مدل	نوع	شاخص هوش AA	MMLU (دانش عمومی)	HumanEval (کدنویسی)	SWE-Bench (کد واقعی)
GPT-5.5	اختصاصی	~۶۰	—	—	—
Claude Opus 4.7	اختصاصی	۵۷	—	—	—
Claude Sonnet 5	اختصاصی	—	٪۸۹.۰	٪۹۴.۵	٪۶۵.۰
GPT-4o	اختصاصی	—	٪۸۸.۷	٪۹۲.۱	٪۴۸.۰
DeepSeek V4 Flash	منبع باز	—	٪۸۷.۰	٪۸۹.۰	٪۳۵.۰
Llama 4 Maverick	منبع باز	—	٪۸۴.۰	٪۸۲.۰	٪۲۲.۰
MiMo-V2.5	منبع باز	۴۰	—	—	—

🔴 نکته تحلیلی عملکرد:

شاخص هوش AA ترکیبی از ۱۰ ارزیابی مستقل است و معیار قابل اعتمادی برای توانایی کلی مدل محسوب می‌شود.

مشاهده می‌شود که مدل‌های منبع‌باز مانند DeepSeek V4 و Llama 4 عملکردی نزدیک به مدل‌های اختصاصی دارند، اما با هزینه‌ای به مراتب کمتر.

۴. قیمت‌گذاری API (به ازای هر ۱ میلیون توکن)

قیمت‌ها بر اساس ارائه‌دهندگان مختلف در ژوئیه ۲۰۲۶ جمع‌آوری شده است. (تمامی ارقام به دلار آمریکا است.)

مدل	ارائه‌دهنده	قیمت ورودی (\$) (\$)	قیمت خروجی (\$) (\$)	قیمت کش‌شده (\$)	پنجره زمینه
DeepSeek V4 Flash	DeepSeek (رسمی)	0.14\$	0.28\$	0.0028\$	۱ میلیون
MiMo-V2.5	شیائومی (رسمی)	0.14\$	0.28\$	0.003\$	۱ میلیون
Llama 4 Scout	Lambda	0.05\$	0.10\$	—	۱۰ میلیون
Llama 4 Scout	Amazon Bedrock	0.17\$	0.66\$	—	۱۰ میلیون
Qwen-Flash	Alibaba	0.05\$	0.40\$	0.01\$	۲۵۶ هزار
Qwen3.5-Flash	Alibaba	0.10\$	0.40\$	—	۱ میلیون
Qwen3-Coder-Next	Alibaba	0.07\$	0.30\$	—	۲۶۲ هزار
Llama 4 Maverick	Together AI	0.27\$	0.85\$	—	۱ میلیون
DeepSeek V4 Pro	DeepSeek (رسمی)	0.435\$	0.87\$	0.0036\$	۱ میلیون
GPT-4o	OpenAI	2.50\$	10.00\$	—	۱ میلیون

۱ میلیون	—	25.00\$	5.00\$	Anthropic	Claude Opus 4.7
۱ میلیون	—	30.00\$	5.00\$	OpenAI	GPT-5.5

۵. سناریوهای کاربری و برآورد هزینه ماهانه API

سه سناریوی معمول برای مصرف توکن در نظر گرفته شده است:

سناریو	ورودی ماهانه	خروجی ماهانه	مدل انتخابی	هزینه ماهانه API
کاربر سبک (استفاده شخصی روزانه)	۰.۳ میلیون	۰.۱ میلیون	DeepSeek V4 Flash	$+ 0.14\$ \times 0.3$ $0.07\$ = 0.28\$ \times 0.1$
کاربر متوسط (توسعه‌دهنده، ۲۰ روز کاری)	۱۰ میلیون	۵ میلیون	MiMo-V2.5	$+ 0.14\$ \times 10$ $2.80\$ = 0.28\$ \times 5$
کاربر سنگین (پلتفرم با ترافیک بالا)	۱۰۰ میلیون	۳۰ میلیون	Qwen-Flash	$+ 0.05\$ \times 100$ $17.00\$ = 0.40\$ \times 30$

نتیجه سناریوها: برای اکثر کاربران حقیقی و تیم‌های کوچک، هزینه ماهانه کمتر از 20\$ است که بسیار مقرون به صرفه می‌باشد.

۶. تحلیل نقطه‌سر به سر (Break-Even) خودمیزبانی در مقابل API

نقطه‌سر به سر زمانی رخ می‌دهد که هزینه ماهانه API = هزینه ثابت خودمیزبانی. در صورتی که مصرف از این نقطه فراتر رود، خودمیزبانی به صرفه‌تر خواهد بود.

سناریوی اول: میزبانی مدل Llama 3.3 70B (با کوانتیزاسیون INT4)

- هزینه خودمیزبانی: حدود 4,000\$ در ماه برای اجاره ابری (2 × GPU A100 یا 1 × H100) - یا با سخت‌افزار اختصاصی حدود 15,000\$ هزینه اولیه.
- هزینه API معادل: اگر از مدل اختصاصی سطح بالا مانند GPT-5 با قیمت ~15\$ به ازای هر میلیون توکن استفاده کنیم، نقطه‌سر به سر برابر است با: $15 / 4000 \approx 267$ میلیون توکن در ماه (حدود ۹ میلیون توکن در روز).

سناریوی دوم: میزبانی Llama 70B در مقابل API ارزان قیمت منبع باز (مثلاً MiMo-V2.5 با نرخ ترکیبی 0.06\$)

اگر به جای GPT-5 از MiMo-V2.5 با قیمت $\sim 0.06\$$ به ازای هر میلیون توکن (نرخ ترکیبی) استفاده کنیم، نقطه سر به سر به شدت افزایش می‌یابد:

$$0.06 / 4000 \approx 66,667 \text{ میلیون توکن در ماه } (\sim 2.2 \text{ میلیارد توکن در روز}).$$

نتیجه: در برابر API‌های بسیار ارزان، خودمیزبانی تقریباً هرگز به صرفه نیست مگر در حجم‌های نجومی.

سناریوی سوم: میزبانی مدل‌های بزرگ و پیشرفته مانند Llama 4 Maverick

- این مدل‌ها نیاز به ۴ تا ۸ GPU سازمانی دارند و هزینه ماهانه بین $2,000\$$ تا $20,000\$$ متغیر است.
- اگر API معادل آن (مثلاً Llama 4 Scout روی Lambda با قیمت $0.05\$$ ورودی) در نظر گرفته شود، نقطه سر به سر حتی در پایین‌ترین هزینه ($2,000\$$) برابر است با: $0.05 / 2000 = 40,000$ میلیون توکن در ماه (بیش از ۱.۳ میلیارد توکن در روز).

۷. جدول خلاصه نقاط سر به سر

مدل خودمیزبانی	هزینه ماهانه	جایگزین API	قیمت هر ۱م توکن	نقطه سر به سر (ماهانه)	نقطه سر به سر (روزانه)
Llama 3.3 70B	4,000\$	GPT-5 (اختصاصی)	15.00\$	۲۶۷ میلیون توکن	۸.۹ میلیون توکن
Llama 3.3 70B	4,000\$	MiMo-V2.5 (منبع باز)	0.06\$	۶۶,۶۶۷ میلیون توکن	۲,۲۲۲ میلیون توکن
Llama 4 Maverick	10,000\$	Llama 4 Scout (Lambda)	0.05\$	۲۰۰,۰۰۰ میلیون توکن	۶,۶۶۷ میلیون توکن

۸. جمع‌بندی و توصیه‌های نهایی

گروه کاربری	توصیه	دلیل
افراد و تیم‌های کوچک	استفاده از API (DeepSeek, MiMo, Qwen)	هزینه ماهانه کمتر از 20\$، بدون نیاز به زیرساخت
استارت‌آپ‌ها در حال رشد	شروع با API، نظارت بر مصرف	در صورت رسیدن هزینه ماهانه به بیش از 3,000\$ تا 5,000\$، مهاجرت به خودمیزبانی بررسی شود

شرکت‌های بزرگ با ترافیک بالا	بررسی خودمیزبانی	در حجم بیش از ۱۰ میلیون توکن در روز، خودمیزبانی می‌تواند ۶۰ تا ۸۰٪ صرفه‌جویی داشته باشد
برنامه‌های با الزامات حریم خصوصی	خودمیزبانی	داده‌ها هرگز از زیرساخت داخلی خارج نمی‌شود